

Lab 1,

1.3,

Mọi quyết định trong text processing (như tokenization, stop-word, stemming, ...) sẽ thay đổi sự biểu diễn của tài liệu. Sự biểu diễn của tài liệu thay đổi làm cách hệ thống so khớp tài liệu thay đổi làm ảnh hưởng đến độ chính xác và chất lượng kết quả tìm kiếm.

Ex 1,

$$(D-1) = [1, 0, 1, 1, 0]$$

$$(D-2) = [0, 1, 1, 1, 0]$$

$$(D-3) = [1, 0, 0, 1, 1]$$

Ex 2,

$$tf(Cat, D_1) = \frac{1}{3}, \quad tf(fish, D_1) = \frac{1}{3}$$

$$tf(eats, D_1) = \frac{1}{3} \quad \sum_t tf(t, D_1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$$

Ex 3,

$$idf(t) = \log \frac{N}{df(t)}$$

$$idf(Cat) = \log \frac{3}{df(Cat)} = \log \frac{3}{2} \approx 0,18$$

$$idf(dog) = \log \frac{3}{1} \approx 0,48$$

$$idf(eats) = \log \frac{3}{2} \approx 0,18$$

$$idf(fish) = \log \frac{3}{3} = 0$$

$$idf(likes) = \log \frac{3}{1} \approx 0,48$$

$\Rightarrow idf(fish)$ min vì xuất hiện nhiều nhất.

Ex 4,

$$TF-IDF(cod) = \frac{1}{3} \cdot \log \frac{1}{1} = 0$$

$$TF-IDF(cas) = \frac{1}{3} \cdot \log \frac{1}{1} = 0$$

$$TF-IDF(fish) = \frac{1}{3} \cdot \log \frac{1}{1} = 0$$

$$TF-IDF(cat) = \frac{1}{3} \cdot 0,18 = 0,06$$

$$TF-IDF(cas) = \frac{1}{3} \cdot 0,18 = 0,06$$

$$TF-IDF(fish) = \frac{1}{3} \cdot 0 = 0$$

- Vì fish xuất hiện ở 2 tài liệu nên nó có giá trị phân bố giữa các tài liệu.

Ex 5,

$$\cos(x, y) = \frac{x \cdot y}{\|x\|_2 \|y\|_2} = \frac{2}{\sqrt{3} \cdot \sqrt{2}} \approx 0,812$$

Vì cosine similarity đo độ giống nhau về hướng của 2 vector, ở như
đó là số hạng ngang nhau.

Ex 6)

1) D1

2) D3

3) medical và image

4) Lỗi.

6) Part C - production before Experiment.

- Production 1 - Nếu corpus có 30K documents, vocabulary sẽ có khoảng 200K unique term.

- Production 2 - Sparsity.

+ TF-IDF matrix sẽ sparse.

+ TF-IDF matrix có kích cỡ:

$$30.000 \cdot 200.000 = 6.000.000.000 \text{ (entries)}$$

mà mỗi document có khoảng 100 - 300 terms.

TOTAL

20

15

10

5

⇒ Zero entries có trong

~~6000000000~~
~~300~~

$$\left[\frac{6000000000}{300}, \frac{6000000000}{1000} \right]$$

$$\Rightarrow [\cancel{6000000000}; 6002000000; 6000000000]$$