LAB 04 — Text Classification

Môn học: Xử lý ngôn ngữ tự nhiên và ứng dụng | **Học kỳ:** Học kỳ I - 2026

Giảng viên / TA: Phạm Ngọc Hải ▪ **Hạn nộp:** 23:59 - 14/10/2026

Chủ đề: From Text Representation to Supervised NLP

1. Bối cảnh

Ở các lab trước, sinh viên đã xây dựng ba thành phần nền tảng:

- LAB 01: biểu diễn văn bản bằng TF-IDF;
- LAB 02: mô hình hóa xác suất của chuỗi bằng n-gram language model;
- LAB 03: biểu diễn từ bằng dense word embeddings.

Trong lab này, các representation trên được đưa vào một bài toán NLP có nhãn:

> **Text Classification**

Ví dụ:

- spam / not spam;
- positive / negative sentiment;
- topic classification;
- intent classification;
- medical document classification.

Mục tiêu không chỉ là xây dựng một classifier có accuracy cao.

Sinh viên phải trả lời được:

> **Representation nào phù hợp với bài toán nào, tại sao, và model đang sai ở đâu?**

---

2. Mục tiêu học tập

Sau khi hoàn thành lab, sinh viên có thể:

- **LO1:** Formulate text classification as a supervised learning problem.
- **LO2:** Xây dựng train/validation/test split đúng cách.
- **LO3:** Chuyển văn bản thành feature vectors.
- **LO4:** Huấn luyện một classifier cơ bản cho dữ liệu văn bản.
- **LO5:** So sánh TF-IDF và word-embedding representations.
- **LO6:** Tính và diễn giải confusion matrix, precision, recall và F1.
- **LO7:** Nhận diện class imbalance và data leakage.
- **LO8:** Phân tích lỗi classification dựa trên dữ liệu thực tế.
- **LO9:** Hiểu ảnh hưởng của representation và preprocessing tới classifier.
- **LO10:** Nhận diện giới hạn của bag-of-words và static embeddings.

---

3. Cấu trúc lab

Giai đoạn	Thời lượng	Hoạt động
Theory recap	20 phút	Supervised text classification
Calculation	25 phút	Prediction, logits, metrics
Prediction	10 phút	Dự đoán model
Experiment 1	20 phút	Dataset & class distribution
Core implementation	35 phút	TF-IDF + classifier

Giai đoạn	Thời lượng	Hoạt động
Experiment 2	30 phút	Representation comparison
Evaluation	30 phút	Precision/Recall/F1
Application	25 phút	Real classification task
Error analysis	25 phút	Misclassified examples
Reflection	10 phút	Representation → neural NLP

---

4. Theory recap

4.1 Bài toán classification

Cho dataset:

$$D = \{(x_i, y_i)\}_{i=1}^{N}.$$

Trong đó:

- (x_i): văn bản;
- (y_i): nhãn.

Ví dụ:

```
"I love this movie"       → positive
"This movie is terrible"  → negative
```

Model học:

$$f(x) \to y.$$

Trong thực tế:

```
raw text
   ↓
preprocessing
   ↓
representation
   ↓
classifier
   ↓
prediction
```

---

5. Representation

Từ LAB 01:

$$x \to TF\text{-}IDF \to \vec{x}.$$

Từ LAB 03:

$$x \to word\ embeddings \to document\ representation.$$

Câu hỏi trọng tâm:

Hai classifier giống nhau nhưng representation khác nhau có cho kết quả giống nhau không?

Prediction trước khi chạy:

```
TF-IDF
vs
Average Word2Vec
```

Sinh viên phải dự đoán representation nào phù hợp hơn cho dataset được giao và giải thích.

---

6. Bài tập tính toán

Bài 1 — Binary classification

Cho:

$$x = [1, 2, 0]$$

và:

$$w = [0.5, -0.2, 0.4].$$

Bias:

$$b = 0.1.$$

Tính:

$$z = w^T x + b.$$

Sau đó sử dụng sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Tính xác suất:

$$P(y = 1|x).$$

---

7. Bài 2 — Prediction threshold

Giả sử:

$$P(y = 1|x) = 0.72.$$

Với threshold:

$$\tau = 0.5,$$

model dự đoán class nào?

Sau đó xét:

$$\tau = 0.8.$$

Model dự đoán class nào?

Trả lời:

Thay đổi threshold có thể làm precision và recall thay đổi như thế nào?

---

8. Bài 3 — Confusion matrix

Cho:

	Predicted Positive	Predicted Negative
Actual Positive	80	20
Actual Negative	10	90

Tính:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2PR}{P + R}.$$

Sau đó trả lời:

Nếu đây là bài toán phát hiện spam, false positive và false negative có ý nghĩa gì?

---

9. Bài 4 — Accuracy trap

Dataset có:

```
950 negative
50 positive
```

Một model dự đoán:

```
mọi sample → negative
```

Accuracy là:

$$\frac{950}{1000} = 95\%.$$

Sinh viên phải trả lời:

Model này có thực sự tốt không?

Không yêu cầu đưa ra "model tốt/xấu" một cách cảm tính. Phải chỉ ra **metric nào cần xem thêm**. Đây là bước rất quan trọng để chống việc sinh viên chỉ nhìn accuracy.

---

10. Prediction trước experiment

Trước khi chạy model, sinh viên dự đoán:

Prediction 1

TF-IDF + Logistic Regression có khả năng hoạt động tốt không?

Prediction 2

Average Word2Vec có chắc chắn tốt hơn TF-IDF không?

Prediction 3

Nếu tăng vocabulary size thì accuracy chắc chắn tăng không?

Prediction 4

Nếu bỏ stopwords thì performance chắc chắn tăng không?

Prediction 5

Accuracy và F1 có thể cho kết luận khác nhau không?

Ghi:

```
Prediction:
Reason:
Confidence:
```

---

11. Experiment 1 — Dataset inspection

Dataset	Task	Độ khó
20 Newsgroups	Topic classification	□□□
AG News	News classification	□□
IMDb	Sentiment	□□□
SMS Spam Collection	Spam detection	□
TREC-6	Intent/question classification	□□□
SST-2	Sentiment	□□□
Yelp Polarity	Sentiment	□□
DBPedia	Topic classification	□□□
SNLI	Natural language inference	□□□□
Quora Question Pairs	Semantic similarity	□□□

Lựa chọn dataset trong bảng trên. Các em có thể download từ Hugging Face hoặc Kaggle. Trước khi train model, sinh viên **không được train ngay**.

Phải kiểm tra:

- số samples;
- số classes;

- class distribution;
- document length;
- duplicate documents;
- missing text;
- missing labels.

Ví dụ:

Class	Count	Percentage
Positive	...	...
Negative	...	...

Vẽ phân phối class.

Sau đó trả lời:

> Dataset có imbalance không?

---

12. Data leakage

Đây là một phần bắt buộc.

Sinh viên phải hiểu pipeline đúng:

```
Dataset
   ↓
Train / Validation / Test split
   ↓
Fit preprocessing trên TRAIN
   ↓
Transform Validation/Test
   ↓
Train model
```

Không được:

```
Entire dataset
   ↓
Fit TF-IDF
   ↓
Train/Test split
```

vì vocabulary/IDF của test set đã được sử dụng.

Câu hỏi:

> Vì sao đây là data leakage?

---

13. Core implementation

Sinh viên xây dựng pipeline:

```
Raw text
   ↓
TF-IDF
   ↓
Classifier
   ↓
```

```
Prediction
   ↓
Evaluation
```

Classifier đầu tiên:

```
Logistic Regression
```

Có thể sử dụng:

```
TfidfVectorizer
LogisticRegression
```

ở phần application.

Không cần tự implement toàn bộ Logistic Regression từ đầu ở lab này, vì mục tiêu chính là **NLP pipeline và representation**.

Tuy nhiên sinh viên phải hiểu:

$$z = w^T x + b$$

và:

$$P(y = 1|x) = \sigma(z).$$

---

14. Experiment 2 — Baseline

Xây dựng baseline:

```
TF-IDF
+
Logistic Regression
```

Ghi:

- training time;
- vocabulary size;
- accuracy;
- precision;
- recall;
- F1.

Kết quả:

Model	Accuracy	Precision	Recall	F1
TF-IDF + LR				

Không được chỉ báo cáo accuracy.

---

15. Experiment 3 — Representation comparison

Đây là **thí nghiệm chính của LAB 04**.

So sánh:

Model A

```
TF-IDF
   ↓
Logistic Regression
```

Model B

```
Average Word2Vec
   ↓
Logistic Regression
```

Model C

Có thể thêm:

```
TF-IDF
+
Linear SVM
```

nếu thời gian cho phép.

Bảng:

Representation	Classifier	Accuracy	Precision	Recall	F1
TF-IDF	Logistic Regression				
Avg Word2Vec	Logistic Regression				
TF-IDF	Linear SVM				

---

16. Câu hỏi quan trọng

Không hỏi:

> Model nào có accuracy cao nhất?

Mà hỏi:

> **Tại sao hai representation tạo ra kết quả khác nhau?**

Sinh viên phải dựa vào đặc tính:

TF-IDF

- sparse;
- lexical;
- giữ thông tin term;
- phù hợp với từ/phrase đặc trưng.

Word2Vec average

- dense;
- semantic;
- mất word order;
- một từ có một vector;
- averaging có thể làm mất thông tin quan trọng.

---

17. Experiment 4 — Word order

Đây là experiment rất đáng làm.

Cho:

```
S1 = "this movie is good"

S2 = "this movie is not good"
```

Nếu sử dụng average word embeddings:

$$\vec{x} = \frac{1}{n} \sum_i \vec{w}_i,$$

thì:

```
good
```

và:

```
not
```

chỉ được cộng vào vector.

Đặt câu hỏi:

> Representation này có hiểu được vai trò của `not` không?

Đây là một ví dụ trực tiếp về limitation của bag-of-words và averaged embeddings.

---

18. Experiment 5 — n-gram features

Mở rộng TF-IDF:

```
unigram
```

so với:

```
unigram + bigram
```

Ví dụ:

```
"not good"
```

và:

```
"very good"
```

có thể trở thành các features riêng.

So sánh:

Features	Vocabulary	F1	Training time
Unigram			
Uni + Bigram			

Câu hỏi:

Vì sao bigram có thể giúp classification nhưng đồng thời làm feature space lớn hơn?

---

19. Evaluation

Sinh viên phải báo cáo:

Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}.$$

Precision

$$Precision = \frac{TP}{TP + FP}.$$

Recall

$$Recall = \frac{TP}{TP + FN}.$$

F1

$$F1 = 2\frac{Precision \cdot Recall}{Precision + Recall}.$$

---

20. Confusion matrix

Bắt buộc phải vẽ confusion matrix.

Ví dụ:

```
              Predicted
              Pos   Neg
Actual Pos     TP    FN
       Neg     FP    TN
```

Sinh viên phải tìm:

- class nào bị nhầm nhiều nhất;
- loại error nào chiếm nhiều;
- metric nào phản ánh vấn đề đó.

---

21. Error analysis

Chọn ít nhất:

```
3 correctly classified
3 incorrectly classified
```

Ví dụ:

Text	True	Predicted	Analysis
…	positive	positive	…

Text	True	Predicted	Analysis
...	negative	positive	...
...	positive	negative	...

Với mỗi lỗi, xác định:

```
lexical ambiguity
negation
sarcasm
short text
rare word
domain-specific term
data noise
class imbalance
```

Không yêu cầu tất cả phải thuộc một category.

---

22. Một experiment rất hay: Inspect model weights

Với Logistic Regression + TF-IDF:

$$z = w^T x + b.$$

Các feature có:

$$w_i \gg 0$$

có xu hướng đóng góp vào class positive.

Các feature có:

$$w_i \ll 0$$

có xu hướng đóng góp vào class negative.

Sinh viên tìm:

```
Top positive features
Top negative features
```

Ví dụ:

Feature	Weight
excellent	...
amazing	...
terrible	...
boring	...

Sau đó trả lời:

Những feature này có thực sự có ý nghĩa đối với task không?

Đây là bước đầu tiên để sinh viên tiếp cận **model interpretability**.

---

23. Application

Chọn một bài toán thực tế.

Chọn một trong:

Option A — Sentiment classification

```
positive
negative
```

Dễ triển khai và dễ hiểu.

Option B — Topic classification

```
sports
business
technology
politics
```

Phù hợp để cho thấy vocabulary/domain differences.

Option C — Intent classification

```
refund
cancel_order
track_order
payment_problem
```

Rất phù hợp để dẫn tới conversational AI sau này.

Nếu muốn thống nhất toàn bộ môn, **sentiment hoặc topic classification** sẽ dễ triển khai nhất ở LAB 04.

---

25. Individual learning check

Random một câu trong 3 phút:

Tại sao accuracy 95% chưa chắc tốt?

hoặc:

TF-IDF khác average Word2Vec ở điểm nào?

hoặc:

Tại sao `not good` có thể gây lỗi?

hoặc:

Data leakage xảy ra ở đâu nếu fit TF-IDF trước khi split?

hoặc:

Precision và recall khác nhau thế nào?

hoặc:

Tại sao thêm bigram có thể cải thiện sentiment classification?

---

26. Deliverables

```
lab04/
├── README.md
├── calculations.md
├── prediction.md
├── classification.ipynb
├── preprocessing.py
├── results.csv
├── confusion_matrix.png
├── error_analysis.md
└── reflection.md
```

---

27. Rubric

Thành phần	Điểm
Theory & calculation	10
Prediction	10
Data inspection & split	10
Baseline implementation	15
Representation comparison	15
Quantitative evaluation	15

Thành phần	Điểm
Error analysis	10
Model interpretation	5
Reflection	5
Individual learning check	5
Tổng	**100**

---

28. Peer assessment

Reviewer cần kiểm:

```
Dataset
[ ] Train/test split hợp lệ
[ ] Không có leakage
[ ] Class distribution được báo cáo

Model
[ ] Baseline chạy được
[ ] Có ít nhất 2 representation/model
[ ] Metrics đầy đủ

Analysis
[ ] Confusion matrix
[ ] 3 lỗi được phân tích
[ ] Có giải thích representation ảnh hưởng thế nào

Interpretation
[ ] Top features được kiểm tra
[ ] Không chỉ báo cáo accuracy
```

---

29. Mạch nối LAB 01 → LAB 04

Đến đây curriculum bắt đầu có một cấu trúc rất rõ:

```
LAB 01
Text
 ↓
TF-IDF
 ↓
Sparse representation
 ↓
Search
```

```
LAB 02
Text
 ↓
N-gram
 ↓
Probability
 ↓
Language Model
 ↓
Perplexity
```

```
LAB 03
Text
 ↓
Context
 ↓
Word Embedding
 ↓
Semantic Similarity
```

```
LAB 04
Text
 ↓
Representation
 ↓
Classifier
 ↓
Prediction
 ↓
Evaluation
 ↓
Error Analysis
```

Và quan trọng nhất, LAB 04 cho sinh viên thấy một vấn đề:

$$\boxed{\text{TF-IDF} \neq \text{semantic understanding}}$$

và:

$$\boxed{\text{Word2Vec} \neq \text{contextual understanding}}$$

Ví dụ:

```
"I like this movie"
"I do not like this movie"
```

hoặc:

```
"bank" = financial institution
"bank" = river bank
```

đều bắt đầu bộc lộ giới hạn của representation hiện tại.

Đó là nền tảng rất tốt để **LAB 05 chuyển sang Sequence Models — RNN/LSTM/GRU**, nơi sinh viên lần đầu tiên thấy rằng **thứ tự và context của từ có thể được mô hình hóa trực tiếp**, trước khi đi tới attention và Transformer ở các lab sau.